

LOG650 – Forskningsrapport
Bruk av maskinlæring for forbedring av
etterspørselsprognoser

En komparativ analyse av prognosemodeller for besøksvolum ved Mannsverk

Gård

Student: Kim-Ove Hagerup

Gruppe: G13 – individuell

Emne: LOG650 – Forskningsprosjekt: Logistikk og kunstig intelligens

Dokumentstatus: Rapportutkast til peer-review

Sammendrag

Denne rapporten undersøker hvordan en maskinlæringsbasert prognosemodell kan brukes til å estimere ukentlig besøksvolum ved Mannsverk Gård, og om modellen kan gi lavere prognosefeil enn en enkel referansemodell. Prosjektet er plassert innen området etterspørselsprognoser i kvantitativ logistikk. Den praktiske motivasjonen er at mer presise prognoser kan støtte operativ planlegging av bemanning, råvareinnkjøp og kapasitet i en gårdsvirksomhet med sesongvariasjoner, vekst og nye aktivitetstilbud. Studien er utformet som en kvantitativ og komparativ analyse. Datagrunnlaget består av simulerte ukentlige observasjoner for perioden 2022–2025. Datasettene representerer realistiske mønstre for en lokal gårdsvirksomhet i vekst, inkludert trend, sesong, helligdager, events og strukturelle endringer knyttet til utvikling av gårdsbutikk og gårdscafé. Det analytiske opplegget sammenligner en sesongnaiv referansemodell med

en Random Forest-modell. Modellene evalueres på samme testperiode ved hjelp av MAE og RMSE.

Rapporten er et hovedutkast til peer-review. Resultatdelen beskriver foreløpig evalueringsoppsett og forventet tolkning av modellresultater. Endelige tall, grafer og eventuell sensitivitetsanalyse ferdigstilles i neste revisjon. Foreløpig peker metodeopplegget mot at maskinlæringsmodellen har potensial til å fange opp flere forklaringsvariabler og mer komplekse mønstre enn referansemodellen, men dette må vurderes kritisk mot risiko for overtilpasning, datakvalitet og begrensningene ved simulerte data.

1. Introduksjon

Etterspørselsprognoser er en sentral del av kvantitativ logistikk fordi prognoser danner grunnlag for beslutninger om bemanning, lager, råvareinnkjøp og kapasitetsutnyttelse. I virksomheter der etterspørselen varierer mye mellom uker og sesonger, kan små forbedringer i prognosepresisjon ha praktisk betydning. For høy prognose kan gi overbemanning, unødvendig råvareinnkjøp og økt matsvinn, mens for lav prognose kan gi for lav kapasitet, dårligere kundeopplevelse og tappt omsetning.

Denne studien tar utgangspunkt i Mannsverk Gård i Tverrelvdalen i Alta. Virksomheten kombinerer tradisjonell gårdsdrift med gårdsbutikk, gårdscafé, lokalmat og opplevelsesbasert aktivitet. Når en slik virksomhet utvikler nye tilbud og får mer sesongbasert trafikk, øker behovet for bedre beslutningsstøtte. Ukentlige

besøksprognoser kan gi et mer presist grunnlag for å planlegge hvor mange ansatte som bør være tilgjengelige, hvor mye mat og råvarer som bør klargjøres, og hvordan kapasitet bør disponeres ved helger, ferier og arrangementer.

Rapporten undersøker derfor om maskinlæring kan gi bedre prognosepresisjon enn en enkel referansemodell. Hensikten er ikke å utvikle et komplett driftssystem, men å teste et avgrenset prognoseopplegg som kan dokumenteres, evalueres og drøftes innenfor rammene av LOG650.

1.1 Problemstilling

Studien besvarer følgende problemstilling:

I hvilken grad kan en maskinlæringsbasert prognosemodell redusere prognosefeil ved estimering av ukentlig antall besøkende ved Mannsverk Gård, sammenlignet med en enkel referansemodell, og dermed bidra til mer presis operativ planlegging av bemanning, råvarer og kapasitet?

Problemstillingen er kvantitativ fordi den vurderer modellprestasjon gjennom målbare prognosefeil. Den er også praktisk relevant fordi resultatene knyttes til konkrete operative beslutninger.

1.2 Avgrensning

Prosjektet avgrenses til én målvariabel: ukentlig antall besøkende. Studien sammenligner én referansemodell og én maskinlæringsmodell. Den omfatter ikke full bemanningsoptimering, prisoptimalisering, lønnsomhetsanalyse eller prognoser for enkeltprodukter som kjøtt, jordbær eller kafévarer. Datagrunnlaget er simulert og brukes

for å demonstrere metode, analyseopplegg og praktisk tolkning.

2. Teoretisk rammeverk

2.1 Etterspørselsprognoser i logistikk

Etterspørselsprognoser handler om å estimere fremtidig etterspørsel basert på historiske observasjoner og relevante forklaringsvariabler. I logistikk brukes prognoser som beslutningsgrunnlag for planlegging av varer, kapasitet, personell og transport. For en gårdsvirksomhet med sesongbaserte aktiviteter er etterspørselen ikke jevn gjennom året. Besøk kan påvirkes av ferieperioder, helger, arrangementer, vær, åpning av nye tilbud og generell vekst i interesse for lokalmat og gårdsopplevelser.

Tidsseriedata kjennetegnes ofte av trend, sesong og tilfeldige variasjoner. Trend beskriver langsiktig utvikling over tid. Sesong beskriver systematiske gjentakende mønstre, for eksempel høyere aktivitet om sommeren. Støy beskriver tilfeldige variasjoner som modellen ikke fullt ut kan forklare. En god prognosemodell bør kunne skille mellom disse komponentene på en måte som gir nyttige prediksjoner for fremtidige perioder.

2.2 Referansemodell

En referansemodell brukes som sammenligningsgrunnlag. I denne studien benyttes en sesongnaiv modell. Prinsippet er at en fremtidig verdi predikeres med utgangspunkt i en tidligere observasjon fra en tilsvarende periode. En slik modell er enkel, transparent og krever lite beregning. Den fungerer derfor som en minimumsstandard: en mer avansert modell bør gi bedre prognoser enn denne for å ha praktisk verdi.

Svakheten med referansemodellen er at den i liten grad fanger opp nye strukturelle endringer. Dersom virksomheten åpner nye tilbud, får økt medieoppmerksomhet eller endrer aktivitetsnivå, kan historiske mønstre alene bli for svake til å forklare fremtidig besøksvolum.

2.3 Maskinlæring og Random Forest

Maskinlæring gjør det mulig å trene modeller på historiske data slik at de kan identifisere mønstre og sammenhenger mellom flere variabler. Random Forest er en ensemblemetode basert på mange beslutningstrær. Hvert tre lærer ulike mønstre fra dataene, og den endelige prediksjonen beregnes som en samlet prognose fra trærne.

Metoden er relevant i dette prosjektet fordi den kan kombinere flere forklaringsvariabler, som uke, sesong, trend, helligdager og eventindikatorer.

Fordelen med Random Forest er at modellen kan håndtere ikke-lineære sammenhenger uten at alle sammenhenger må spesifiseres matematisk på forhånd. Ulempen er at modellen kan bli mindre transparent enn en enkel referansem modell, og at den kan overtilpasses dersom datasettet er lite eller variablene er svakt begrunnet.

2.4 Evalueringsmål

Prognosepresisjon vurderes ved hjelp av MAE og RMSE. MAE viser gjennomsnittlig absolutt feil og kan tolkes direkte i antall besøkende per uke. RMSE straffer større feil sterkere fordi avvik kvadreres før gjennomsnitt og rotberegning. Sammen gir målene et bilde av både normal feil og risikoen for store prognoseavvik.

3. Metode

3.1 Forskningsdesign

Studien har et kvantitativt, komparativt design. To modeller testes på samme datagrunnlag og evalueres på samme testperiode. Designet er egnet fordi problemstillingen handler om målbar reduksjon i prognosefeil. Et komparativt oppsett gjør det mulig å vurdere om en maskinlæringsmodell faktisk tilfører verdi sammenlignet med en enkel modell.

For å unngå informasjonslekkasje behandles dataene kronologisk. Det innebærer at modellen trenes på tidligere observasjoner og evalueres på senere observasjoner. Dette er viktig i tidsserieprognoser, fordi fremtidig informasjon ikke skal være tilgjengelig når modellen trenes.

3.2 Data og variabler

Datagrunnlaget består av simulerte ukentlige observasjoner for perioden 2022–2025. Simuleringen er valgt fordi reelle besøksdata foreløpig ikke er tilgjengelige. Dataene er likevel konstruert for å representere realistiske trekk ved en lokal gårdsvirksomhet i vekst.

Variabelgruppe	Eksempel	Formål i modellen
Målvariabel	Ukentlig antall besøkende	Verdien som skal predikeres
Tid og sesong	Uke, måned, sommerperiode	Fanger sesongmønstre
Trend	Løpende ukeindeks	Fanger generell vekst over tid
Helligdager og ferier	Påske, sommerferie, jul	Fanger perioder med avvikende aktivitet
Events	Planlagte arrangementer	Fanger ekstraordinært besøksvolum
Strukturelle skift	Gårdsbutikk og gårdscafé	Fanger endringer i virksomhetens tilbud

Tabell 1. Oversikt over sentrale variabelgrupper i datagrunnlaget.

3.3 Modelloppsett

Modelloppsettet følger en enkel struktur: parametre, variabler og mål. Parametrene består av historiske besøksdata og forklaringsvariabler. Variabelen som predikeres er ukentlig besøksvolum. Målet er å minimere prognosefeil målt ved MAE og RMSE.

Modell	Input	Output	Rolle i studien
Sesongnaiv referansemodell	Tidligere observasjoner	Predikert besøksvolum	Sammenligningsgrunnlag
Random Forest	Tid, sesong, trend, helligdager, events og strukturelle skift	Predikert besøksvolum	Maskinlæringsmodell som testes mot referanse

Tabell 2. Modellene som sammenlignes i studien.

3.4 Evalueringsopplegg

Datasettene deles i trenings- og testsett ved en kronologisk 80/20-splitt. Begge modeller trenes og evalueres på samme datagrunnlag. Dette gir sammenlignbarhet og reduserer risikoen for at forskjeller i resultat skyldes ulike testbetingelser. Evalueringsmålene MAE og RMSE beregnes for begge modeller.

4. Analyse

Analysen gjennomføres ved å sammenligne modellens predikerte verdier med faktiske verdier i testperioden. Referansemodellen gir et enkelt bilde av hvor godt historiske sesongmønstre alene kan forklare fremtidige besøkstall. Random Forest-modellen tester om flere forklaringsvariabler samlet kan gi lavere prognosefeil.

Et sentralt analysepunkt er om maskinlæringsmodellen gir forbedring som er praktisk relevant, ikke bare statistisk målbar. Dersom reduksjonen i MAE er liten, kan en enkel referansemodell være tilstrekkelig. Dersom reduksjonen er tydelig, kan maskinlæring gi bedre beslutningsstøtte for bemanning, råvareplanlegging og kapasitetsstyring.

Siden rapporten er et utkast til peer-review, er endelige resultattall og figurer ikke ferdigstilt i denne versjonen. Analyseopplegget er likevel definert slik at resultatene kan etterprøves og fullføres i neste revisjon.

5. Foreløpige resultater

De foreløpige resultatene peker i retning av at maskinlæringsmodellen kan oppnå lavere prognosefeil enn referansemodellen. Dette er forventet dersom besøksvolumet påvirkes av flere samtidige faktorer enn tidligere ukers observasjoner alene. Random Forest-modellen har særlig potensial til å fange opp kombinasjoner av trend, sesong, helligdager og strukturelle skift.

Modell	MAE	RMSE	Tolkning
Sesongnaiv referansem modell	Beregnes i endelig analyse	Beregnes i endelig analyse	Minimumsnivå for sammenligning Forventes å fange
Random Forest	Beregnes i endelig analyse	Beregnes i endelig analyse	flere forklaringsvariable r

Tabell 3. Resultatstruktur for endelig modell sammenligning.

I endelig rapport vil tabellen erstattes eller suppleres med beregnede verdier, grafisk sammenligning av prediksjoner mot faktiske observasjoner og en vurdering av om forbedringen er praktisk betydningsfull.

6. Diskusjon

Dersom Random Forest-modellen oppnår lavere MAE og RMSE enn referansem modellen, kan dette forklares med at modellen utnytter et bredere informasjonsgrunnlag. Mens den sesongnaive modellen primært viderefører historiske mønstre, kan maskinlæringsmodellen lære sammenhenger mellom flere forklaringsvariabler. Dette er særlig relevant når virksomheten har strukturelle endringer, for eksempel åpning av nye tilbud eller økt aktivitet gjennom events og turisme.

Den praktiske nytten av en bedre prognose må vurderes opp mot beslutningene prognosen skal støtte. For Mannsverk Gård kan en forbedret ukesprognose bidra til bedre bemanningsplanlegging, riktigere råvareinnkjøp og mer effektiv bruk av kapasitet. En mer presis prognose kan også redusere matsvinn ved at kafé og butikk planlegger produksjon og innkjøp nærmere forventet behov.

Samtidig må resultatene tolkes kritisk. For det første bygger studien på simulerte data.

Selv om dataene er konstruert realistisk, kan de ikke fullt ut erstatte reelle observasjoner. For det andre kan maskinlæringsmodeller overtilpasses, særlig når antall observasjoner er begrenset. En modell kan da prestere godt på treningsdata, men dårligere på nye perioder. For det tredje kan forklaringsvariabler som virker relevante i simuleringen, ha svakere forklaringskraft i virkelige data.

En viktig faglig vurdering er derfor ikke bare hvilken modell som har lavest feil, men om modellen er robust, forståelig og praktisk anvendbar. I en liten virksomhet kan en enkel modell være lettere å vedlikeholde, mens en maskinlæringsmodell kan være mer presis dersom datagrunnlaget er godt nok. Valg av modell bør derfor baseres på en samlet vurdering av prognosepresisjon, datakvalitet, kompleksitet og bruksverdi.

7. Konklusjon

Studien undersøker om en maskinlæringsbasert prognosemodell kan redusere prognosefeil ved estimering av ukentlig besøksvolum ved Mannsverk Gård sammenlignet med en enkel referansemodell. Rapporten viser at problemstillingen egner seg for en kvantitativ og komparativ analyse, og at Random Forest er en relevant metode når besøksvolum påvirkes av flere forklaringsvariabler.

Foreløpig konkluderes det med at maskinlæring har potensial til å forbedre prognosepresisjonen og dermed styrke operativ planlegging av bemanning, råvarer og kapasitet. Endelig konklusjon forutsetter ferdig beregning av MAE og RMSE, samt en kritisk vurdering av om eventuell forbedring er stor nok til å ha praktisk verdi.

8. Begrensninger

Studien har flere begrensninger. Datagrunnlaget er simulert, og resultatene kan derfor ikke uten videre generaliseres til faktisk drift ved Mannsverk Gård. Studien sammenligner kun én maskinlæringsmodell med én referansemodell. Det gjennomføres heller ikke full optimering av bemanning, innkjøp eller kapasitet. Prosjektet må derfor forstås som en metodisk modelltest, ikke som et ferdig beslutningssystem.

9. Videre arbeid

Videre arbeid bør prioritere tre forbedringer. Først bør analysen gjennomføres med reelle besøksdata dersom slike data blir tilgjengelige. Deretter bør flere modeller testes, for eksempel XGBoost, SARIMA eller eksponentiell glatting. Til slutt bør prognosene kobles tydeligere til operative beslutninger, slik at man kan vurdere hvordan en gitt reduksjon i MAE faktisk påvirker bemanning, råvareinnkjøp og kapasitetsbruk.

10. Bruk av KI

Kunstig intelligens er brukt som støtteverktøy i arbeidet med rapportstruktur, språklig forbedring, metodeformulering og planlegging av analyseopplegg. KI er også brukt som støtte i vurdering av hvordan Python-kode og modellering kan dokumenteres. Alt faglig innhold, metodevalg og endelige formuleringer er gjennomgått og kvalitetssikret av studenten. KI er ikke brukt som selvstendig fagkilde.

Referanser

Breiman, L. (2001). Random forests. *Machine Learning*, 45, 5–32.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data*

mining, inference, and prediction (2. utg.). Springer.

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3. utg.).

OTexts.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning* (2. utg.). Springer.

Pettersen, B.-I., & Rekdal, P. K. (2026). *Kvantitative metoder i logistikk – implementert via*

KI. Kompendium i LOG650.

Rekdal, P. K., & Pettersen, B.-I. (2025). *Vitenskapelig skriving – en praktisk innføring.*

Kompendium i LOG650.